



Nama : Triyana Dewi Fatmawati

NIM : 2241720206

Kelas : TI - 3D

Nomor : 21

Mata Kuliah: Big Data

Tugas 7 – Spark Docker

Praktikum:

Interaksi dengan Spark di Lingkungan Windows Menggunakan Docker

Pengerjaan:

1. Pull Image Spark Resmi

docker pull apache/spark:latest

```
PS C:\Users\TRIYANA DF> docker pull apache/spark:latest
latest: Pulling from apache/spark
d9802f032d67: Pulling fs layer
3058f73b8f49: Pull complete
f937e0a2086c: Pull complete
Of3083818c14: Pull complete
4d9bb71a5e54: Pull complete
b072aa17899d: Pull complete
5762a181dda2: Pull complete
1ba3910f6ba2: Pull complete
4f4fb700ef54: Pull complete
391ef20df327: Pull complete
Digest: sha256:39321d67b23e2e0953f81b60778f74bf40c40a18dfb0e881e6a38593af60afa1
Status: Downloaded newer image for apache/spark:latest
docker.io/apache/spark:latest
PS C:\Users\TRIYANA DF>
```

2. Menjalankan Spark Master

Sebelumnya buat docker network sebagai berikut

```
PS C:\Users\TRIYANA DF> docker network create spark-net 58decf0eba52c8fe8ac240fd53ba0cbe7b31492a109e402df9e0a9907bc5fbf4 PS C:\Users\TRIYANA DF>
```

Kemudian jalankan spark-master dalam network tersebut

PS C:\Users\TRIYANA DF> docker run -d -p 8080:8080 -p 7077:7077 --name spark-master --network spark-net -m 2g --cpus=2 apache /spark:latest /opt/spark/bln/spark-class org.apache.spark.deploy.master.Master b72fc8a231390fb0b122fa55d066cef49fe5fbde0ce4b82173b5925912c88540

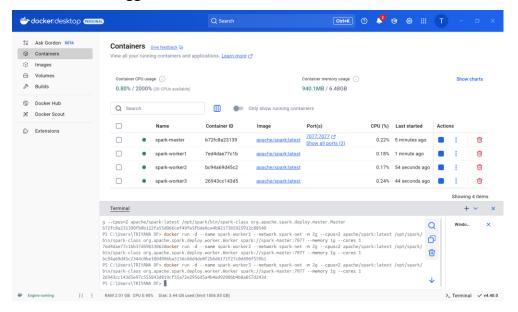
Kita alokasikan resource untuk memastikan tidak kekurangan resource dalam menjalankan job.

3. Menjalankan Spark Worker

Kita perlu alokasikan resource misalnya 2G memori dan 2 core CPU.

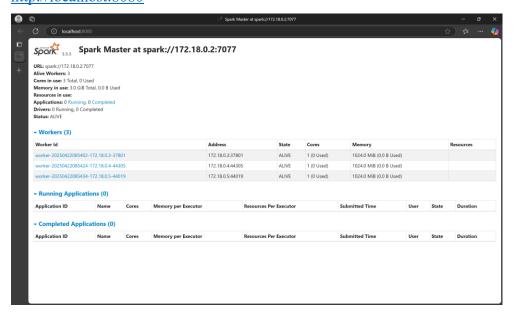
PS C:\Users\TRIYANA DF> docker run -d --name spark-worker1 --network spark-net -m 2g --cpus=2 apache/spark:latest /opt/spark/bin/spark-class org.apache.spark.deploy.worker.Worker spark://spark-master:7077 --memory 1g --cores 1
7ed4dae77c1bb37d69b53862docker run -d --name spark-worker2 --network spark-net -m 2g --cpus=2 apache/spark:latest /opt/spark/bin/spark-class org.apache.spark.deploy.worker.Worker spark://spark-master:7077 --memory 1g --cores 1
bc94a69d45c2344c0be1004906ba5156c66d4de8f2b6d6171f27c0d496f559b1
PS C:\Users\TRIYANA DF> docker run -d --name spark-worker3 --network spark-net -m 2g --cpus=2 apache/spark:latest /opt/spark/bin/spark-class org.apache.spark.deploy.worker.Worker3 --network spark-master:7077 --memory 1g --cores 1
26943cc143d5e97c555843d819cf55a72e2956d5a4b4ed92000bb4b8a057d243d

Berikut hasil menggunakan 3 worker.



4. Mengakses Spark Web UI

http://localhost:8080

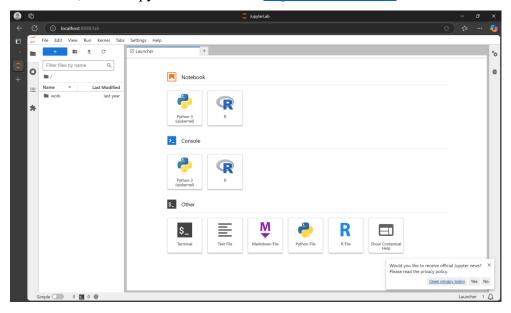


5. Menjalankan Spark Shell

6. Menggunakan Jupyter Notebook dengan Spark

PS C:\Users\TRIYANA DF> docker run -it -p 8888:8888 -p 4040:4040 --network spark-net jupyter/all-spark-notebook Unable to find image 'jupyter/all-spark-notebook:latest' locally latest: Pulling from jupyter/all-spark-notebook

Setelah itu, akses Jupyter Notebook di: http://localhost:8888



7. Untuk menghentikan container:

docker stop spark-master spark-worker docker rm spark-master spark-worker

```
PS C:\Users\TRIYANA DF> docker stop spark-master spark-worker1 spark-worker2 spark-worker3 spark-master spark-worker1 spark-worker1 spark-worker2 spark-worker3
PS C:\Users\TRIYANA DF> docker rm spark-master spark-worker1 spark-worker2 spark-worker3 spark-master spark-worker1 spark-worker1 spark-worker2 spark-worker3
PS C:\Users\TRIYANA DF>
```

Contoh Program Word Count dengan Spark di Docker

Berikut adalah contoh program Word Count (menghitung kemunculan kata) menggunakan Apache Spark yang bisa dijalankan di lingkungan Docker:

Cara 1: Menggunakan Spark Shell

- 1. Jalankan Spark Shell di Docker seperti contoh di atas
- 2. Ketikkan kode berikut di Spark Shell:

```
scala> val textData = List("Hello Spark", "Hello Docker", "Spark is awesome", "Docker makes Spark easy")
textData: List[String] = List(Hello Spark, Hello Docker, Spark is awesome, Docker makes Spark easy)
rdd: org.apache.spark.rdd.RDD[String] = ParallelCollectionRDD[0] at parallelize at <console>:24
scala> val wordCounts = rdd
  .flatMap(line => line.split(" "))
                                               // Memecah setiap baris jadi kata
                                               // Membuat pasangan (kata, 1)
// Menggabungkan jumlah per kata
  .map(word => (word, 1))
   .reduceByKey(_ + _)
wordCounts: org.apache.spark.rdd.RDD[String] = ParallelCollectionRDD[0] at parallelize at <console>:24
scala> res0: org.apache.spark.rdd.RDD[String] = MapPartitionsRDD[1] at flatMap at <console>:24
1 = ShuffledRDD[31 at reduceBvKev at <console>:24
scala> wordCounts.collect().foreach(println)
[Stage 0:>
                                                                                                                        Hello Spark
Hello Docker
Spark is awesome
Docker makes Spark easy
```

Untuk keluar dari spark-shell gunakan: System.exit(0)

```
scala> System.exit(0)
PS C:\Users\TRIYANA DF>
```

Cara 2: Menggunakan PySpark (Python)

1. Jalankan PySpark Shell di Docker:

Dalam command juga terdapat definisi network juga.

2. Ketikkan kode Python berikut:

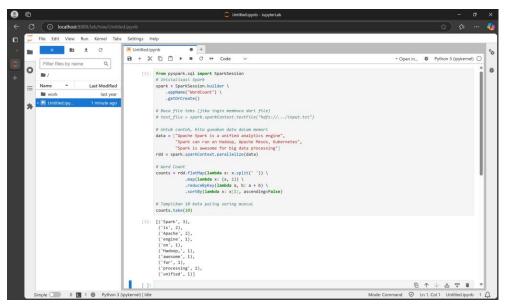
```
>>> from pyspark.sql import SparkSession
>>> spark = SparkSession.builder.appName("WordCount").getOrCreate()
>>> data = ["Hello Spark", "Hello Docker", "Spark is awesome", "Docker makes Spark easy"]
>>> rdd = spark.sparkContext.parallelize(data)
>>> word_counts = rdd.flatMap(lambda line: line.split(" ")) \
... .map(lambda word: (word, 1)) \
... .reduceByKey(lambda a, b: a + b)
>>> word_counts.collect()
[Stage 0:>
[('Spark', 3), ('awesome', 1), ('Docker', 2), ('easy', 1), ('Hello', 2), ('is', 1), ('makes', 1)]
```

Untuk keluar dari pyspark-shel menggunakan: exit()

```
>>> exit()
PS C:\Users\TRIYANA DF>
```

Cara 3: Menggunakan Jupyter Notebook

Seperti di container jupyter/all-spark-notebook, akses Jupyter Notebook di: http://localhost:8888



Menjalankan Program sebagai Script

1. Buat file wordcount.py dengan isi berikut:

2. Jalankan script, jangan lupa juga mendifinisikan network spark-net

```
PS C:\Users\TRIYANA DF\app> docker run --rm --network spark-net -v ${PWD}:/app --link spark-master:spark-master apache /spark:latest /opt/spark/bin/spark-submit --master spark://spark-master:7077 /app/Wordcount.py 25/04/22 22:02:28 INFO SparkContext: Running Spark version 3.5.5 25/04/22 22:02:28 INFO SparkContext: OS info Linux, 5.15.167.4-microsoft-standard-WSL2, amd64 25/04/22 22:02:28 INFO SparkContext: Java version 11.0.26
```

Perhatikan dalam command tersebut mendifinisikan akses data ke local.

Program-program di atas akan menghasilkan output seperti:

```
25/04/22 22:12:13 INFO DAGScheduler: Job 0 finished: collect at /app/Wordcount.py:17, took 5.946905 s Hello: 2 Spark: 2 is: 1 awesome: 1 Docker: 1 25/04/22 22:12:13 INFO SparkContext: SparkContext is stopping with exitCode 0.
```

Tugas:

Menjalankan Apache Spark di Azure

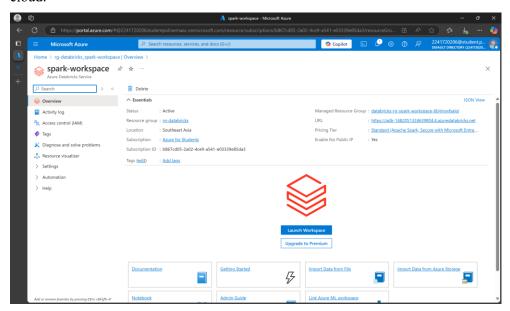
Pengerjaan:

Langkah-langkah untuk menjalankan Apache Spark di Azure:

Disini saya menggunakan Azure Databricks yaitu layanan analytics berbasis Apache Spark yang dikelola sepenuhnya oleh Azure.

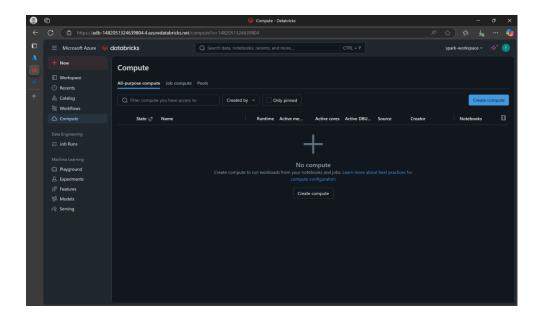
Langkah 1: Buat Azure Databricks Workspace

Pertama, saya membuat layanan Azure Databricks melalui portal Azure untuk menjalankan Spark di cloud.



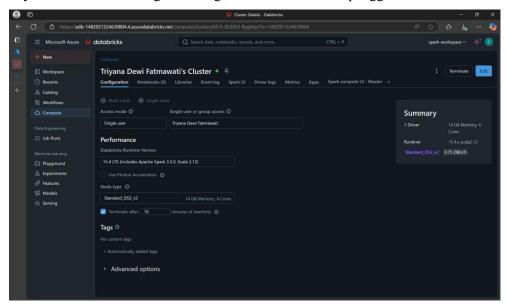
Langkah 2: Masuk ke Databricks Workspace

Setelah workspace berhasil dibuat, saya masuk ke dalamnya dengan klik Launch Workspace untuk mulai menggunakan fitur-fitur yang tersedia.



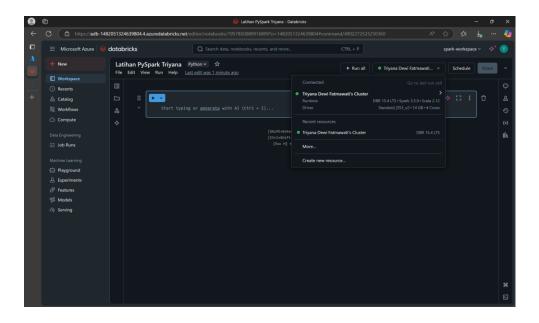
Langkah 3: Buat Cluster

Selanjutnya, saya membuat cluster yang berfungsi sebagai "mesin" untuk menjalankan kode Spark. Saya memilih cluster single node agar lebih hemat dalam penggunaan kredit.



Langkah 4: Buat Notebook & Jalankan Spark

Kemudian, saya membuat sebuah notebook di dalam workspace. Notebook ini digunakan sebagai tempat untuk menulis dan menjalankan kode Spark.



Langkah 5: Tulis Kode PySpark

Terakhir, saya menulis kode PySpark di notebook untuk memastikan bahwa Spark sudah berhasil dijalankan di Azure.

