



Nama : Triyana Dewi Fatmawati

NIM : 2241720206

Kelas : TI - 3D

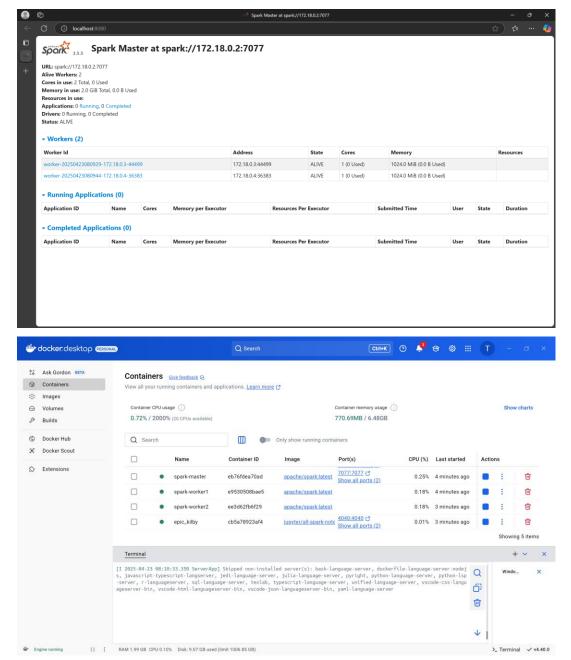
Nomor : 21

Mata Kuliah : Big Data

# Tugas 9 - Spark SQL, DataSources, DataFrame, dan Dataset APIs

#### Pengerjaan:

### Menyiapkan lingkungan Spark Cluster

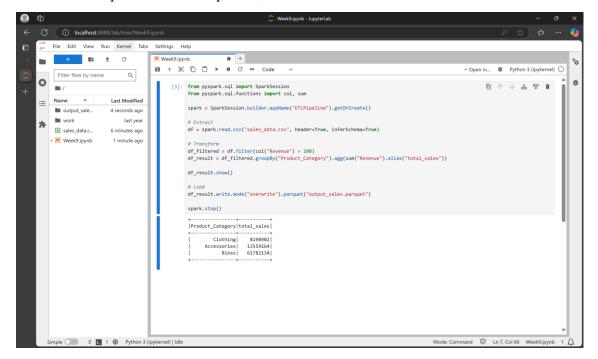


### Praktikum Membangun ETL Pipeline

1. Extract: Baca data dari file CSV (sales\_data.csv).

### 2. Transform:

- o Filter transaksi dengan Revenue > \$100.
- o Hitung total penjualan per kategori.
- 3. Load: Simpan hasil ke Parquet.



### **Analisis Data Retail**

### **Dataset**

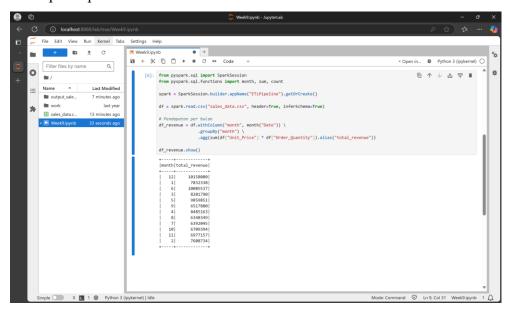
• Format: CSV (sales\_data.csv)

## **Tugas**

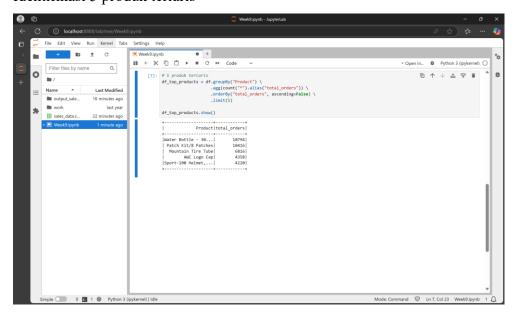
- 1. Hitung total pendapatan per bulan.
- 2. Identifikasi 5 produk terlaris.
- 3. Simpan hasil dalam format Parquet.

# Pengerjaan

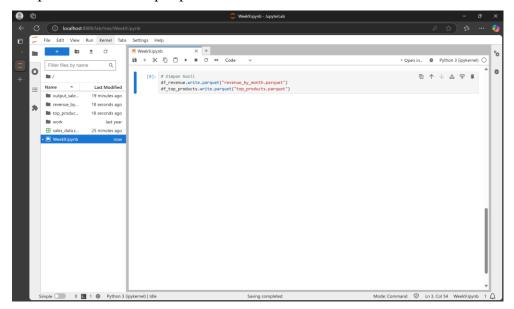
1. Pendapatan perbulan



2. Identifikasi 5 produk terlaris



3. Simpan dalam format parquet



### **Evaluasi**

### **Soal Latihan**

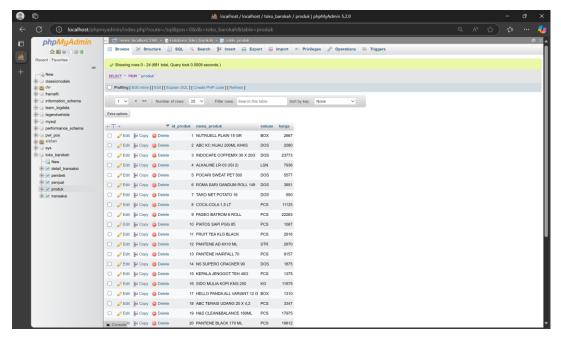
1. Baca data dari tabel di database MySQL anda menggunakan Spark, dengan cara berikut

```
df = spark.read.format("jdbc") \
    .option("url", "jdbc:mysql://localhost:3306/db") \
    .option("dbtable", "table_name") \
    .option("user", "user") \
    .option("password", "password") \
    .load()
```

Baca tabel apa saja.

2. Buat query Spark SQL untuk menghitung Jumlah row dalam tabel tersebut

### Pengerjaan:



Pada pengerjaan soal latihan ini saya menggunakan database "toko\_barokah" tabel "produk".

#### 1. Baca tabel

Saya membaca tabel "produk" dan menampilkan 5 produk teratas.

### 2. Query menghitung jumlah row dalam tabel

```
[5]: # Daftarkan DataFrame jadi table sementara
df.createOrReplaceTempView("produk")

# Query Spark SQL untuk menghitung jumlah baris
hasil = spark.sql("SELECT COUNT(*) AS jumlah_row FROM produk")

# Tampilkan hasil
hasil.show()

+-----+
| jumlah_row|
+-----+
| 681|
+------+
```

# Kesimpulan

- Spark SQL menyediakan antarmuka terstruktur untuk pemrosesan data besar.
- DataFrame & Dataset APIs memungkinkan manipulasi data dengan sintaks mirip SQL.
- DataSources API mendukung integrasi dengan berbagai format penyimpanan.